

AI-driven Learning for Education and Cooperation (Alec)

Documentazione attraverso protocollo CRISP-DM del progetto
Alec.

Davide Viola

7 ottobre 2025

<https://github.com/davidviola63/Alec-AIProject.git>

Indice

1	Business Understanding	2
1.1	Contesto	2
1.2	Obiettivi di business	2
1.3	Requisiti	2
1.3.1	Requisiti funzionali	2
1.3.2	Requisiti non funzionali	3
1.4	Criteri di successo	3
1.5	Ambito del progetto	4
2	Data Understanding	4
2.1	Raccolta dei dati	4
2.2	Descrizione dei dati	5
2.3	Esplorazione dei dati	5
2.4	Verifica della qualità dei dati	6
3	Data Preparation	6
3.1	Selezione dei dati	7
3.2	Pulizia dei dati	7
3.3	Trasformazione dei dati	8
3.4	Dataset finale	8

1 Business Understanding

1.1 Contesto

Il progetto, intitolato *AI-driven Learning for Education and Cooperation* (Alec), nasce per dare concretezza allo studio e all'analisi eseguiti sui LLM in ambito educativo svolto da me. A corredo del progetto sarà disponibile anche il paper relativo allo studio consultabile su GitHub. L'obiettivo di Alec è quello di proporsi come tutor virtuale a supporto della metodologia di peer learning tra studenti, offrendo un aiuto personalizzato e guidato dai documenti didattici revisionati e forniti dai docenti. Così facendo si offre un duplice beneficio: ridurre il carico di lavoro dei docenti e garantire agli studenti uno strumento in grado di offrire risposte di supporto, sempre coerenti con il materiale del corso, in modo continuo e stimolante.

1.2 Obiettivi di business

L'intento principale del progetto Alec è quello di sperimentare l'uso di tecnologie LLM per migliorare lo studio collaborativo tra studenti. In particolare, il progetto mira a:

- Ridurre la diffusione di errori concettuali durante le sessioni di peer learning, grazie a un sistema che interviene solo in caso di affermazioni scorrette o su esplicita richiesta di aiuto.
- Fornire agli studenti un supporto personalizzato e *scaffolded*, coerente con il materiale didattico e non invasivo, in modo da stimolare l'autonomia e la capacità di ragionamento critico.
- Offrire ai docenti uno strumento che semplifichi il monitoraggio delle attività collaborative, riducendo il carico di lavoro e restituendo report chiari e semplici su partecipazione, punti di forza e aree di miglioramento degli studenti.
- Creare le basi per un modello scalabile e adattabile ad altri corsi o contesti educativi, mantenendo sempre il controllo dei contenuti da parte dei docenti.

1.3 Requisiti

1.3.1 Requisiti funzionali

I requisiti funzionali descrivono le azioni concrete che il sistema deve essere in grado di compiere. In pratica, definiscono cosa il sistema deve fare per raggiungere gli obiettivi prefissati e supportare l'apprendimento collaborativo.

- **RF-1** Il sistema deve sfruttare principalmente i materiali didattici forniti dal docente come base di conoscenza, con citazioni alla fonte.
- **RF-2** Il sistema deve rispondere quando la soglia di verità è inferiore all'80% o su esplicita richiesta dell'utente.
- **RF-3** Il sistema deve offrire spiegazioni graduali (*scaffolded*) adattate al livello di competenza dell'utente e al tema trattato.

- **RF-4** Il sistema deve mantenere il contesto della conversazione multi-turno distinguendo chiaramente gli interventi dei diversi utenti.
- **RF-5** Il sistema deve tracciare la partecipazione e la qualità degli interventi.
- **RF-6** Il sistema deve generare, al termine della sessione, un report sintetico per docente e studenti con punti di forza, aree di miglioramento e suggerimenti di studio.
- **RF-7** Il sistema deve permettere la gestione dei profili utente.

1.3.2 Requisiti non funzionali

I requisiti non funzionali definiscono le qualità e i vincoli della soluzione web, mantenendo verifiche semplici per l'MVP.

- **RNF-1 (Accuratezza)** Raggiungere un'accuratezza delle correzioni $\geq 85\%$ da test su set di valutazione interno.
- **RNF-2 (Prestazioni back-end)** Mantenere un tempo medio di risposta del tutor $\leq 3s$ su 50 interazioni tipiche di laboratorio.
- **RNF-3 (Prestazioni front-end)** Assicurare un rendering della lista messaggi fluido (scroll senza scatti).
- **RNF-4 (Compatibilità browser)** Supportare le versioni recenti di Chrome, Firefox ed Edge (ultime 2 release principali).
- **RNF-5 (Trasparenza)** Includere, dove possibile, una citazione alla fonte interna per ogni correzione.
- **RNF-6 (Manutenibilità)** Consentire ai docenti di aggiornare facilmente i materiali didattici e gestire le sessioni di tutoring senza conoscenze tecniche.

1.4 Criteri di successo

Il progetto si considera completato con successo quando il prototipo rispetta i vincoli descritti nei requisiti non funzionali e ha implementato tutti i requisiti funzionali ad alta priorità, inoltre deve dimostrare, attraverso test di laboratorio, di poter operare in maniera stabile e comprensibile. In particolare, si richiede che le correzioni fornite siano sufficientemente accurate, che l'interazione avvenga con tempi di risposta adeguati e che l'interfaccia risulti usabile senza necessità di competenze tecniche avanzate.

Il successo non si misura soltanto sugli aspetti tecnici, ma anche sulla capacità del sistema di mostrarsi come uno strumento efficace per l'apprendimento collaborativo: deve infatti risultare uno strumento innovativo e stimolante attraverso le spiegazioni progressive e personalizzate. Infine i dati appresi durante la conversazione dovranno risultare un punto di partenza per migliorare i percorsi didattici per docenti e studenti.

1.5 Ambito del progetto

Il progetto viene sviluppato da un singolo studente come parte di un tirocinio universitario. Il tempo a disposizione è limitato alla durata del tirocinio e le risorse utilizzabili consistono principalmente in un ambiente di sviluppo locale, librerie software open source e l'accesso a modelli LLM tramite API o strumenti equivalenti.

Nella fase iniziale produrremo un Minimum Viable Product con focus su un singolo corso di studio (Fondamenti di Intelligenza Artificiale) e l'attenzione sarà rivolta esclusivamente alla funzionalità di tutoring: rilevazione di affermazioni scorrette o richieste esplicite di aiuto, fornitura di spiegazioni graduali adattate al livello dello studente, tracciamento della partecipazione e generazione di un report finale. Funzionalità aggiuntive come la proposta di esercizi pratici, l'integrazione di link esterni sicuri e la realizzazione di una dashboard avanzata per i docenti saranno prese in considerazione in cicli successivi, una volta validate le basi del prototipo.

2 Data Understanding

Lo scopo di questa fase è acquisire una chiara comprensione dei dati che costituiranno la base di conoscenza del progetto Alec. In particolare, si tratta dei materiali didattici forniti dai docenti in formato PDF, che verranno analizzati per verificarne la struttura, la qualità e l'idoneità all'utilizzo all'interno del sistema.

Il processo seguito si articola in quattro passaggi principali:

1. **Raccolta:** identificazione e acquisizione dei file PDF pertinenti al corso.
2. **Descrizione:** analisi dei formati e delle principali caratteristiche (numero di documenti, pagine, tipologia di contenuti).
3. **Esplorazione:** valutazione della varietà e complessità dei materiali, con attenzione a testi narrativi, elenchi, formule e tabelle.
4. **Verifica della qualità:** individuazione di criticità come incoerenze terminologiche, mancanza di completezza o contenuti difficilmente leggibili.

L'obiettivo finale è produrre un inventario dei materiali disponibili, evidenziandone le caratteristiche principali e i potenziali problemi da affrontare nelle fasi successive di preparazione e modellazione.

2.1 Raccolta dei dati

La raccolta dei dati è avvenuta attraverso la selezione dei materiali didattici ufficiali messi a disposizione dai docenti del corso. Tali materiali, costituiti principalmente da file in formato PDF (dispense, slide e articoli), sono stati acquisiti tramite una cartella condivisa predisposta dal laboratorio di intelligenza artificiale presente sulla piattaforma e-learning dell'università, nel corso di studio dell'anno 2024 predisposto per le matricole "Resto 1" del dipartimento di informatica.

Per garantire coerenza e affidabilità, sono stati inclusi unicamente i documenti revisionati e approvati dai docenti, escludendo eventuali appunti personali

o risorse di terze parti non validate. I file sono stati organizzati in sottocartelle per modulo e argomento, con una convenzione di nomenclatura uniforme (`Corso/Modulo/Titolo.pdf`) ed è possibile ispezionarli nella cartella `pdf_corsi`, al fine di agevolarne la consultazione e la successiva fase di preparazione. Ad esempio è possibile trovare il file PDF riguardante gli algoritmi di ricerca locale non informata nel percorso:

`FIA/Algoritmi_ricerca/algoritmi_di_ricerca_non_informata.pdf`

2.2 Descrizione dei dati

La seguente tabella sintetizza le caratteristiche principali dei materiali raccolti. Viene presentata come scheda descrittiva, utile a fornire una panoramica generale del dataset disponibile.

Caratteristica	Descrizione
Numero di documenti	26
Dimensione totale approssimata	148 Mb
Tipologia dei documenti	Prevalentemente dispense e slide, seguono estratti di libro, alcuni riferimenti di esercizi e appunti
Lingua	Italiano, Inglese
Formato prevalente	PDF testuale
Elementi presenti	tabelle, formule matematiche, immagini, figure, elenchi puntati
Struttura interna	titoli e sezioni in tutti mentre sottosezioni e numerazione solo negli estratti del libro

Tabella 1: Scheda di descrizione dei dati raccolti

2.3 Esplorazione dei dati

L'esplorazione dei dati ha lo scopo di analizzare il contenuto dei materiali raccolti per comprendere meglio la varietà, la complessità e le caratteristiche rilevanti. Dall'analisi preliminare emergono i seguenti aspetti:

- **Tematiche trattate:** i documenti coprono i contenuti fondamentali del corso di *Fondamenti di Intelligenza Artificiale*. In particolare sono presenti:
 - Algoritmi di ricerca (strategie informate, non informate e locale).
 - Algoritmi con avversari (minimax e varianti).
 - Tecniche di machine learning, tra cui clustering, classificazione e regressione, con accenni ai foundation models e large language models.
 - Documenti dedicati alle fasi del modello CRISP-DM e all'addestramento dei modelli di apprendimento automatico.
 - Documenti riassuntivi per la preparazione all'esame con esercizi, appunti e note offerte dal docente.

- **Tipologia dei contenuti:** le slide e le dispense includono testo descrittivo ed elenchi puntati, frequenti immagini esplicative accompagnate da didascalie, schemi concettuali, oltre a scarse formule matematiche ed esempi di applicazione. Si può riscontrare anche la presenza di pseudocodice nelle slide sugli algoritmi di ricerca.
- **Livello del linguaggio:** il linguaggio adottato è formale e preciso, ma al tempo stesso scorrevole e non eccessivamente rigoroso. Questo lo rende accessibile e comprensibile anche a studenti che affrontano per la prima volta gli argomenti trattati.
- **Eterogeneità dei documenti:** l'eterogeneità risulta complessivamente molto sottile. I materiali si adattano bene alla tematica trattata ed evitano ripetizioni eccessive, mantenendo uno stile uniforme tra i diversi PDF. L'unica eccezione è rappresentata dai documenti forniti per esercitarsi, che presentano uno stile leggermente diverso. La lunghezza media dei documenti è di circa 45 pagine, valore che li rende gestibili e coerenti per lo studio.

2.4 Verifica della qualità dei dati

La verifica della qualità dei dati si occupa di valutare l'affidabilità e l'idoneità dei materiali raccolti. Dall'analisi preliminare emergono le seguenti considerazioni:

- **Leggibilità:** i PDF sono in gran parte testuali e quindi direttamente processabili. Non sono state individuate scansioni di bassa qualità che possano compromettere l'estrazione dei contenuti.
- **Uniformità:** lo stile dei documenti è omogeneo e facilita la coerenza complessiva del dataset. L'unica eccezione è rappresentata dal materiale per esercitazioni, che presenta uno stile leggermente diverso.
- **Completezza:** i contenuti raccolti risultano coerenti con il programma del corso, coprendo sia gli argomenti di base (algoritmi di ricerca e con avversari) sia quelli avanzati (machine learning, LLM, fasi CRISP-DM).
- **Ridondanza:** non sono emerse ripetizioni eccessive o ridondanze tra i documenti, favorendo una gestione snella del corpus.
- **Potenziati criticità:** la presenza di formule matematiche, schemi e alcune tabelle potrebbe richiedere attenzione nella fase di preparazione, in quanto non sempre sono rappresentate in formato testuale.
- **Dimensioni:** la lunghezza media dei documenti, pari a circa 45 pagine, si dimostra gestibile e adeguata per le successive fasi di segmentazione e indicizzazione.

3 Data Preparation

La fase di *Data Preparation* ha lo scopo di trasformare i materiali raccolti nella fase precedente in un dataset strutturato, pulito e pronto per essere utilizzato dal sistema.

Mentre la fase di *Data Understanding* si è concentrata sull'analisi e sulla valutazione preliminare dei dati disponibili, in questa fase vengono eseguite tutte le operazioni necessarie per rendere i contenuti effettivamente utilizzabili. In particolare, l'attività di preparazione comprende la selezione dei documenti rilevanti, la pulizia e la normalizzazione dei file PDF, la loro segmentazione in unità più piccole e gestibili, e l'arricchimento con metadati utili per la successiva fase di modellazione. L'obiettivo finale è disporre di un corpus coerente e ben organizzato, in grado di supportare l'interazione tra studenti e tutor virtuale e di garantire risposte basate esclusivamente sui materiali didattici forniti dai docenti.

3.1 Selezione dei dati

A partire dall'insieme di documenti raccolti nella fase di *Data Understanding*, è stato effettuato un processo di selezione mirato a definire il corpus utilizzabile. Tale selezione non ha comportato l'acquisizione di nuovi materiali, ma piuttosto una distinzione e organizzazione dei documenti già raccolti.

In particolare:

- Sono stati confermati i materiali didattici ufficiali forniti dai docenti come base di conoscenza principale.
- È stata effettuata una separazione tra documenti teorici (dispense, slide, articoli) e materiali di esercitazione, mantenendo entrambi ma distinguendoli per tipologia d'uso.
- Sono stati esclusi eventuali duplicati e documenti non pertinenti alla tematica del corso.
- I file sono stati rinominati e organizzati in sottocartelle per modulo e argomento, al fine di garantire uniformità e semplicità di gestione nelle fasi successive.

3.2 Pulizia dei dati

La fase di pulizia dei dati ha avuto l'obiettivo di garantire che i documenti selezionati risultassero coerenti, leggibili e privi di elementi di disturbo. Le operazioni principali hanno riguardato:

- Eliminazione di pagine vuote, copertine ridondanti e versioni duplicate degli stessi file.
- Accorpamento di slide ripetute con leggere differenze ed eliminazione di slide che non avrebbero apportato contributo alla spiegazione.
- Verifica che tutti i PDF fossero in formato testuale leggibile, con assenza di sezioni scansionate come immagini non processabili.
- Selezione delle immagini dove quelle chiare e di supporto al contenuto testuale sono state mantenute, mentre sono state rimosse o trasformate in descrizioni testuali quelle potenzialmente malformate o di difficile interpretazione.

- Uniformazione della nomenclatura dei file e correzione di caratteri anomali, per garantire un encoding coerente.
- Rimozione di elementi non essenziali (indici ripetuti, numerazioni incoerenti) che potevano generare rumore nella fase di elaborazione.

Da questa fase abbiamo ottenuto documenti prevalentemente testuali, coerenti e privi di rumore, pronti per la successiva fase di trasformazione e segmentazione.

3.3 Trasformazione dei dati

Una volta completata la selezione e la pulizia dei materiali didattici, si è proceduto con la fase di trasformazione, necessaria per rendere i documenti effettivamente utilizzabili dal modello. In particolare, i file PDF sono stati caricati su un bucket di *Google Cloud Storage*, in modo da essere accessibili all'interno della piattaforma *Vertex AI*. Successivamente, attraverso l'uso del modulo *RAG Engine* di *Vertex AI*, i documenti sono stati segmentati in unità di testo più piccole (chunk) e normalizzati, così da costituire un corpus interrogabile dal modello generativo Gemini. Le principali operazioni svolte sono state:

- Conversione dei documenti PDF in testo, con gestione delle eventuali sezioni miste (testo e immagini).
- Segmentazione del contenuto in blocchi di dimensione media pari a 512 token, con un margine di sovrapposizione pari a 80 token per preservare la coerenza tra le sezioni contigue.
- Associazione di metadati a ciascun blocco, tra cui il nome del file e la struttura di cartelle di origine, in modo da poter risalire facilmente all'argomento o al modulo di appartenenza.

Il risultato finale di questa fase è un corpus RAG coerente, indicizzato e arricchito di metadati, pronto per essere interrogato dal modello Gemini nella successiva fase di modellazione.

3.4 Dataset finale

Al termine del processo di preparazione, i materiali didattici selezionati, puliti e trasformati costituiscono un corpus unificato e strutturato. Questo insieme di dati comprende sia documenti teorici (dispense e slide) sia materiali di esercitazione, per un totale di N file PDF organizzati in moduli e argomenti. Dopo la segmentazione e l'importazione nel sistema, il corpus risulta composto da circa X pagine e Y unità testuali (chunk), ciascuna arricchita di metadati relativi all'origine del contenuto.

Il corpus così ottenuto rappresenta il dataset finale della fase di *Data Preparation*. Esso costituisce la base di conoscenza ufficiale e controllata su cui verranno effettuate le interrogazioni nella fase di *Modeling*. In questa fase successiva, il modello Gemini, opportunamente integrato con il motore di recupero RAG, utilizzerà i chunk indicizzati per generare risposte pertinenti e motivate, fornendo agli studenti un supporto diretto basato esclusivamente sui materiali approvati dai docenti.