

AI-driven Learning for Education and Cooperation (Alec)

Documentazione attraverso protocollo CRISP-DM del progetto
Alec.

Davide Viola

16 ottobre 2025

<https://github.com/davidviola63/Alec-AIProject.git>

Indice

1	Business Understanding	2
1.1	Contesto	2
1.2	Obiettivi di business	2
1.3	Requisiti	2
1.3.1	Requisiti funzionali	2
1.3.2	Requisiti non funzionali	3
1.4	Criteri di successo	3
1.5	Ambito del progetto	3
2	Data Understanding	4
2.1	Raccolta dei dati	4
2.2	Descrizione dei dati	5
2.3	Esplorazione dei dati	5
2.4	Verifica della qualità dei dati	6
3	Data Preparation	6
3.1	Selezione dei dati	6
3.2	Pulizia dei dati	7
3.3	Trasformazione dei dati e dataset finale	7

1 Business Understanding

1.1 Contesto

Il progetto, intitolato *AI-driven Learning for Education and Cooperation* (Alec), nasce per dare concretezza allo studio e all'analisi eseguiti sui LLM in ambito educativo svolto da me. A corredo del progetto sarà disponibile anche il paper relativo allo studio consultabile su GitHub. L'obiettivo di Alec è quello di proporsi come tutor virtuale a supporto della metodologia di peer learning tra studenti, offrendo un aiuto personalizzato e guidato dai documenti didattici revisionati e forniti dai docenti. Così facendo si offre un duplice beneficio: ridurre il carico di lavoro dei docenti e garantire agli studenti uno strumento in grado di offrire risposte di supporto, sempre coerenti con il materiale del corso, in modo continuo e stimolante.

1.2 Obiettivi di business

L'intento principale del progetto Alec è quello di sperimentare l'uso di tecnologie LLM per migliorare lo studio collaborativo tra studenti. In particolare, il progetto mira a:

- Ridurre la diffusione di errori concettuali durante le sessioni di peer learning, grazie a un sistema che interviene solo in caso di affermazioni scorrette o su esplicita richiesta di aiuto.
- Fornire agli studenti un supporto personalizzato e *scaffolded*, coerente con il materiale didattico e non invasivo, in modo da stimolare l'autonomia e la capacità di ragionamento critico.
- Offrire ai docenti uno strumento che semplifichi il monitoraggio delle attività collaborative, riducendo il carico di lavoro e restituendo report chiari e semplici su partecipazione, punti di forza e aree di miglioramento degli studenti.
- Creare le basi per un modello scalabile e adattabile ad altri corsi o contesti educativi, mantenendo sempre il controllo dei contenuti da parte dei docenti.

1.3 Requisiti

1.3.1 Requisiti funzionali

I requisiti funzionali descrivono le azioni concrete che il sistema deve essere in grado di compiere. In pratica, definiscono cosa il sistema deve fare per raggiungere gli obiettivi prefissati e supportare l'apprendimento collaborativo.

- **RF-1** Il sistema deve sfruttare principalmente i materiali didattici forniti dal docente come base di conoscenza, con citazioni alla fonte.
- **RF-2** Il sistema deve rispondere quando la soglia di verità è inferiore all'80% o su esplicita richiesta dell'utente.
- **RF-3** Il sistema deve offrire spiegazioni graduali (scaffolded) adattate al livello di competenza dell'utente e al tema trattato.

- **RF-4** Il sistema deve mantenere il contesto della conversazione multi-turno distinguendo chiaramente gli interventi dei diversi utenti.
- **RF-5** Il sistema deve tracciare la partecipazione e la qualità degli interventi.
- **RF-6** Il sistema deve generare, al termine della sessione, un report sintetico per docente e studenti con punti di forza, aree di miglioramento e suggerimenti di studio.

1.3.2 Requisiti non funzionali

I requisiti non funzionali definiscono le qualità e i vincoli della soluzione web, mantenendo verifiche semplici per l'MVP.

- **RNF-1 (Accuratezza)** Raggiungere un'accuratezza delle correzioni $\geq 85\%$ da test su set di valutazione interno.
- **RNF-2 (Prestazioni back-end)** Mantenere un tempo medio di risposta del tutor $\leq 25s$ su 50 interazioni tipiche di laboratorio.
- **RNF-3 (Trasparenza)** Includere, dove possibile, una citazione alla fonte interna per ogni correzione.
- **RNF-4 (Manutenibilità)** Consentire ai docenti di aggiornare facilmente i materiali didattici e gestire le sessioni di tutoring senza conoscenze tecniche.

1.4 Criteri di successo

Il progetto si considera completato con successo quando il prototipo rispetta i vincoli descritti nei requisiti non funzionali e ha implementato tutti i requisiti funzionali, inoltre deve dimostrare, attraverso test di laboratorio, di poter operare in maniera stabile e comprensibile. In particolare, si richiede che le correzioni fornite siano sufficientemente accurate, che l'interazione avvenga con tempi di risposta adeguati e che l'interfaccia risulti usabile senza necessità di competenze tecniche avanzate.

Il successo non si misura soltanto sugli aspetti tecnici, ma anche sulla capacità del sistema di mostrarsi come uno strumento efficace per l'apprendimento collaborativo: deve infatti risultare uno strumento innovativo e stimolante attraverso le spiegazioni progressive e personalizzate. Infine i dati appresi durante la conversazione dovranno risultare un punto di partenza per migliorare i percorsi didattici per docenti e studenti.

1.5 Ambito del progetto

Il progetto viene sviluppato da un singolo studente come parte di un tirocinio universitario. Il tempo a disposizione è limitato alla durata del tirocinio e le risorse utilizzabili consistono principalmente in un ambiente di sviluppo locale, librerie software open source e l'accesso a modelli LLM tramite API o strumenti equivalenti.

Nella fase iniziale produrremo un Minimum Viable Product con focus su un singolo corso di studio (Fondamenti di Intelligenza Artificiale) e l'attenzione sarà

rivolta esclusivamente alla funzionalità di tutoring: rilevazione di affermazioni scorrette o richieste esplicite di aiuto, fornitura di spiegazioni graduali adattate al livello dello studente, tracciamento della partecipazione e generazione di un report finale. Funzionalità aggiuntive come la proposta di esercizi pratici, l'integrazione di link esterni sicuri e la realizzazione di una dashboard avanzata per i docenti saranno prese in considerazione in cicli successivi, una volta validate le basi del prototipo.

2 Data Understanding

Lo scopo di questa fase è acquisire una chiara comprensione dei dati che costituiranno la base di conoscenza del progetto Alec. In particolare, si tratta dei materiali didattici forniti dai docenti in formato PDF, che verranno analizzati per verificarne la struttura, la qualità e l'idoneità all'utilizzo all'interno del sistema.

Il processo seguito si articola in quattro passaggi principali:

1. **Raccolta:** identificazione e acquisizione dei file PDF pertinenti al corso.
2. **Descrizione:** analisi dei formati e delle principali caratteristiche (numero di documenti, pagine, tipologia di contenuti).
3. **Esplorazione:** valutazione della varietà e complessità dei materiali, con attenzione a testi narrativi, elenchi, formule e tabelle.
4. **Verifica della qualità:** individuazione di criticità come incoerenze terminologiche, mancanza di completezza o contenuti difficilmente leggibili.

L'obiettivo finale è produrre un inventario dei materiali disponibili, evidenziandone le caratteristiche principali e i potenziali problemi da affrontare nelle fasi successive di preparazione e modellazione.

2.1 Raccolta dei dati

La raccolta dei dati è avvenuta attraverso la selezione dei materiali didattici ufficiali messi a disposizione dai docenti del corso. Tali materiali, costituiti principalmente da file in formato PDF (dispense, slide e articoli), sono stati acquisiti tramite una cartella condivisa predisposta dal laboratorio di intelligenza artificiale presente sulla piattaforma e-learning dell'università, nel corso di studio dell'anno 2024 predisposto per le matricole "Resto 1" del dipartimento di informatica.

Per garantire coerenza e affidabilità, sono stati inclusi unicamente i documenti revisionati e approvati dai docenti, escludendo eventuali appunti personali o risorse di terze parti non validate. I file sono stati organizzati in sottocartelle per modulo e argomento, con una convenzione di nomenclatura uniforme (`Corso/Modulo/Titolo.pdf`) ed è possibile ispezionarli nella cartella `pdf_corsi`, al fine di agevolarne la consultazione e la successiva fase di preparazione. Ad esempio è possibile trovare il file PDF riguardante gli algoritmi di ricerca locale non informata nel percorso:

`FIA/Algoritmi_ricerca/algoritmi_di_ricerca_non_informata.pdf`

2.2 Descrizione dei dati

La seguente tabella sintetizza le caratteristiche principali dei materiali raccolti. Viene presentata come scheda descrittiva, utile a fornire una panoramica generale del dataset disponibile.

Caratteristica	Descrizione
Numero di documenti	26
Dimensione totale approssimata	148 Mb
Tipologia dei documenti	Prevalentemente dispense e slide, seguono estratti di libro, alcuni riferimenti di esercizi e appunti
Lingua	Italiano, Inglese
Formato prevalente	PDF testuale
Elementi presenti	tabelle, formule matematiche, immagini, figure, elenchi puntati
Struttura interna	titoli e sezioni in tutti mentre sottosezioni e numerazione solo negli estratti del libro

Tabella 1: Scheda di descrizione dei dati raccolti

2.3 Esplorazione dei dati

L'esplorazione dei dati ha lo scopo di analizzare il contenuto dei materiali raccolti per comprendere meglio la varietà, la complessità e le caratteristiche rilevanti. Dall'analisi preliminare emergono i seguenti aspetti:

- **Tematiche trattate:** i documenti coprono i contenuti fondamentali del corso di *Fondamenti di Intelligenza Artificiale*. In particolare sono presenti:
 - Algoritmi di ricerca (strategie informate, non informate e locale).
 - Algoritmi con avversari (minimax e varianti).
 - Tecniche di machine learning, tra cui clustering, classificazione e regressione, con accenni ai foundation models e large language models.
- **Tipologia dei contenuti:** le slide e le dispense includono testo descrittivo ed elenchi puntati, frequenti immagini esplicative accompagnate da didascalie, schemi concettuali, oltre a scarse formule matematiche ed esempi di applicazione. Si può riscontrare anche la presenza di pseudocodice nelle slide sugli algoritmi di ricerca.
- **Livello del linguaggio:** il linguaggio adottato è formale e preciso, ma al tempo stesso scorrevole e non eccessivamente rigoroso. Questo lo rende accessibile e comprensibile anche a studenti che affrontano per la prima volta gli argomenti trattati.
- **Eterogeneità dei documenti:** l'eterogeneità risulta complessivamente molto sottile. I materiali si adattano bene alla tematica trattata ed evitano

ripetizioni eccessive, mantenendo uno stile uniforme tra i diversi PDF. La lunghezza media dei documenti è di circa 45 pagine, valore che li rende gestibili e coerenti per lo studio.

2.4 Verifica della qualità dei dati

La verifica della qualità dei dati si occupa di valutare l'affidabilità e l'idoneità dei materiali raccolti. Dall'analisi preliminare emergono le seguenti considerazioni:

- **Leggibilità:** i PDF sono in gran parte testuali e quindi direttamente processabili. Non sono state individuate scansioni di bassa qualità che possano compromettere l'estrazione dei contenuti.
- **Uniformità:** lo stile dei documenti è omogeneo e facilita la coerenza complessiva del dataset. L'unica eccezione è rappresentata dal materiale per esercitazioni, che presenta uno stile leggermente diverso.
- **Completezza:** i contenuti raccolti risultano coerenti con il programma del corso, coprendo sia gli argomenti di base (algoritmi di ricerca e con avversari) sia quelli avanzati (machine learning, LLM, fasi CRISP-DM).
- **Ridondanza:** non sono emerse ripetizioni eccessive o ridondanze tra i documenti, favorendo una gestione snella del corpus.
- **Potenziati criticità:** la presenza di formule matematiche, schemi e alcune tabelle potrebbe richiedere attenzione nella fase di preparazione, in quanto non sempre sono rappresentate in formato testuale.
- **Dimensioni:** la lunghezza media dei documenti, pari a circa 45 pagine, si dimostra gestibile e adeguata per le successive fasi di segmentazione e indicizzazione.

3 Data Preparation

La fase di *Data Preparation* ha l'obiettivo di trasformare i materiali raccolti in un dataset strutturato, pulito e pronto per essere utilizzato dal sistema. Mentre la *Data Understanding* si è concentrata sull'analisi preliminare delle fonti, in questa fase vengono eseguite tutte le operazioni necessarie per rendere i contenuti effettivamente utilizzabili. Le attività comprendono la selezione dei documenti pertinenti, la pulizia e normalizzazione dei file, la loro segmentazione in unità più piccole e l'arricchimento con metadati. Il risultato finale è un corpus coerente e ben organizzato, in grado di supportare l'interazione tra studenti e tutor virtuale, garantendo risposte basate esclusivamente sui materiali didattici forniti dai docenti.

3.1 Selezione dei dati

A partire dall'insieme di documenti individuati nella fase di *Data Understanding*, è stata effettuata una selezione mirata a definire il corpus di riferimento. Questa operazione non ha comportato l'acquisizione di nuovi materiali, ma piuttosto la riorganizzazione di quelli già disponibili. In particolare:

- Sono stati confermati i materiali ufficiali forniti dai docenti come base di conoscenza principale.
- È stata distinta la documentazione teorica (dispense, slide, articoli) dai materiali di esercitazione, mantenendo entrambe le tipologie.
- Sono stati esclusi tutti i file non incentrati sulle slide didattiche come:
 - documenti dedicati al CRISP-DM basati sulle pagine del libro "Machine Learning Engineering" di Burkov.
 - appunti del docente ed esercizi preparatori all'esame

Il motivo di tale esclusione è spinto dalla semplificazione del corpus RAG poichè il libro, scritto in lingua inglese, avrebbe potuto causare difficoltà nell'embedding dei chunk mediante query e difficoltà di multilingua e traduzione; gli appunti del docente, a loro volta, rappresentavano materiale non ufficiale del corso sebbene risultassero di alta qualità didattica.

- I documenti sono stati rinominati e collocati in sottocartelle per modulo e argomento, garantendo uniformità e semplicità di gestione.

3.2 Pulizia dei dati

La fase di pulizia è stata finalizzata a rendere i documenti coerenti, leggibili e privi di rumore. Le principali operazioni hanno riguardato:

- Eliminazione di pagine vuote, copertine ridondanti e versioni duplicate.
- Accorpamento di slide ripetute con minime differenze ed eliminazione di quelle non significative.
- Verifica che i PDF fossero in formato testuale leggibile, evitando sezioni acquisite come immagini non processabili.
- Selezione delle immagini realmente utili al contenuto e conversione in descrizioni testuali di quelle poco chiare o malformate.
- Uniformazione della nomenclatura dei file e correzione di caratteri anomali, così da garantire un encoding coerente.
- Rimozione di elementi ridondanti (indici ripetuti, numerazioni incoerenti) potenzialmente fonte di disturbo.

Al termine della pulizia si sono ottenuti documenti prevalentemente testuali, coerenti e pronti per la fase successiva.

3.3 Trasformazione dei dati e dataset finale

Completata la pulizia, i materiali sono stati trasformati per renderli adatti all'indicizzazione e al recupero tramite *Retrieval-Augmented Generation* (RAG). Il processo è stato condotto in più passaggi:

- **Chunking:** i PDF sono stati suddivisi in blocchi di testo (*chunk*) mediante l'ausilio di *ChatGPT-5 Reasoning*, rispettando un limite di circa 300 token con una sovrapposizione di 60 token tra blocchi consecutivi, così da mantenere continuità semantica. In questa fase i testi sono stati anche normalizzati per migliorarne la leggibilità. Per rendere trasparente il procedimento, di seguito è riportata la query utilizzata:

```
Esegui il chunking di questo PDF.
- Ogni chunk deve contenere al massimo 300 token.
- Usa un overlap di circa 60 token tra i chunk consecutivi.
- Non considerare il titolo delle slide (può essere identico in tutte).
- Basati solo sul contenuto testuale.
- Produci un JSON con struttura minimale:
{
  "doc_id": "...",
  "source": "<nome file PDF>",
  "chunks": [
    { "id": "c01", "text": "..." },
    { "id": "c02", "text": "..." },
    ...
  ]
}
```

- I testi devono essere puliti e coerenti, pronti per l'indicizzazione in FAISS.

- **Costruzione del corpus:** i chunk prodotti sono stati salvati in formato JSON e successivamente aggregati in un unico file tramite lo script `build_corpus`, ottenendo un corpus coerente e uniforme.
- **Embedding e indicizzazione:** il corpus JSON è stato trasformato in vettori semantici (*embedding*) attraverso un modello multilingua, quindi indicizzato con la libreria **FAISS** per consentire interrogazioni rapide ed efficienti.

Il risultato è un **dataset finale** costituito da chunk coerenti e arricchiti di metadati, organizzati in un database vettoriale FAISS. Questo dataset non rappresenta più un insieme statico di documenti, ma una base di conoscenza strutturata ed esplorabile tramite embedding semantici, su cui il sistema potrà effettuare interrogazioni e generare risposte pertinenti. Esso costituisce il riferimento ufficiale e validato su cui si fonda l'intero processo di supporto agli studenti.